

Teleco SLM

Manual de Usuario

Versión 1.0.0

Junio 2026

Inferencia LLM local para ingeniería de telecomunicaciones.

Ejecuta Qwen 3 1.7B Fine-tuned con llama.cpp en CPU, completamente offline.

Arturo Fierro Pardo

Universidad CEU San Pablo

Índice

Índice	2
1. Introducción	3
2. Requisitos del sistema	4
2.1 Android	4
2.2 Windows	4
3. Instalación	5
3.1 Android	5
3.2 Windows	5
4. Primer inicio y configuración	6
4.1 Descarga del modelo	6
4.2 Servidor remoto	6
5. Uso de la aplicación	7
5.1 Pantalla principal	7
5.2 Conversaciones	7
5.3 Renderizado LaTeX	8
6. Ajustes	9
Modelo Local	9
Servidor Remoto	9
Rendimiento	9
Datos	9
Acerca de	9
7. Métricas de inferencia	10
8. Gestión de datos	11
Eliminar conversaciones	11
9. Solución de problemas	12
10. Información técnica	13

1. Introducción

Teleco SLM es una aplicación de inteligencia artificial generativa diseñada para estudiantes y profesionales de ingeniería de telecomunicaciones. La aplicación permite realizar consultas sobre contenidos específicos del dominio de telecomunicaciones y obtener respuestas generadas por un modelo de lenguaje especializado, ejecutado de forma completamente local en el dispositivo del usuario.

El modelo integrado es **Qwen 3 1.7B Fine-tuned**, un Modelo de Lenguaje Pequeño (Mini-SLM) que ha sido ajustado mediante LoRA sobre un corpus de 24.680 pares pregunta-respuesta extraídos del plan de estudios de Ingeniería de Telecomunicaciones de la Universidad CEU San Pablo. El modelo se distribuye en formato GGUF (cuantización Q4_K_M, ~1,1 GB) y se ejecuta mediante llama.cpp, lo que permite inferencia eficiente en CPU sin necesidad de GPU dedicada ni conexión a internet.

La aplicación está disponible para **Android** y **Windows**, con arquitecturas de inferencia adaptadas a cada plataforma.

Características principales:

- Inferencia 100% offline: los datos nunca salen del dispositivo.
- Modelo especializado en telecomunicaciones con soporte de fórmulas matemáticas.
- Renderizado de expresiones LaTeX en las respuestas.
- Historial de conversaciones almacenado localmente (SQLite).
- Panel de métricas de rendimiento (tokens/s, latencia, memoria).
- Descarga directa del modelo desde HuggingFace o carga de archivo local.
- Soporte de conexión a servidor remoto llama-server en red local.

2. Requisitos del sistema

2.1 Android

Componente	Requisito
Sistema operativo	Android 8.0 (API 26) o superior
Arquitectura	ARM64 (aarch64)
RAM mínima	4 GB (recomendado 6 GB o más)
Almacenamiento	~1,5 GB libres (modelo + aplicación)
GPU	No requerida (inferencia en CPU con NEON)
Conexión a internet	Solo para descarga inicial del modelo

2.2 Windows

Componente	Requisito
Sistema operativo	Windows 10/11 (64 bits)
RAM mínima	4 GB (recomendado 8 GB)
Almacenamiento	~1,5 GB libres (modelo + aplicación)
Dependencia	llama-server.exe incluido en la instalación
Conexión a internet	Solo para descarga inicial del modelo

3. Instalación

3.1 Android

La aplicación se distribuye como archivo APK. Para instalarla:

1. Descargar el archivo **TelecoSLM.apk** en el dispositivo Android.
2. Acceder a la carpeta de descargas con un gestor de archivos.
3. Pulsar sobre el archivo APK. Si es la primera vez, el sistema solicitará habilitar la instalación desde orígenes desconocidos en Ajustes > Seguridad.
4. Confirmar la instalación y esperar a que finalice.
5. Abrir la aplicación desde el cajón de aplicaciones.

La aplicación se encuentra también Google Play Store.

3.2 Windows

En Windows, la aplicación se distribuye como carpeta portable o instalador:

1. Descargar la carpeta de distribución de TelecoSLM para Windows.
2. Extraer el contenido en **C:\Program Files\TelecoSLM** o la ubicación deseada.
3. Ejecutar **TelecoSLM.exe** para iniciar la aplicación.
4. El servidor de inferencia **llama-server.exe** se iniciará automáticamente en segundo plano al cargar el modelo.

4. Primer inicio y configuración

Al abrir la aplicación por primera vez, es necesario disponer del modelo de lenguaje para poder realizar inferencias. La pantalla de Ajustes permite configurar la fuente del modelo.

4.1 Descarga del modelo

La sección **Modelo Local** de los ajustes muestra la información del modelo preconfigurado: Qwen 3 1.7B Fine-tuned en formato Q4_K_M (~1,1 GB). Existen dos opciones para obtener el modelo:

- **Descargar modelo:** descarga automática del archivo GGUF desde el repositorio de HuggingFace. Requiere conexión a internet. El progreso se muestra en pantalla.
- **Seleccionar archivo GGUF:** permite cargar un archivo GGUF que ya se encuentre almacenado en el dispositivo. Útil si el modelo fue descargado previamente o se transfirió mediante cable USB.

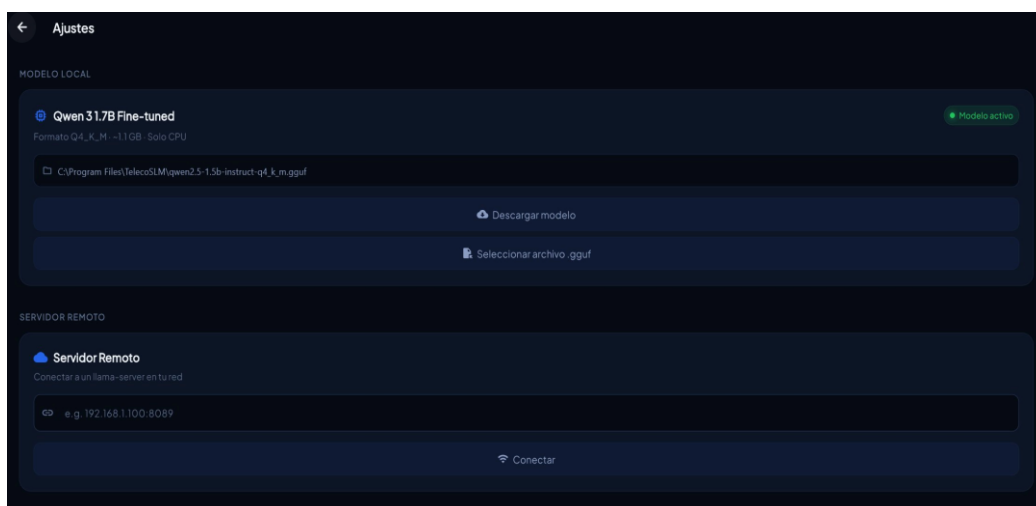


Figura 1. Pantalla de Ajustes — Modelo Local y Servidor Remoto.

Una vez descargado o seleccionado el modelo, la ruta del archivo aparecerá en el campo correspondiente y el indicador **Modelo activo** (punto verde) se mostrará en la cabecera de la aplicación, confirmando que el modelo está cargado y listo para su uso.

4.2 Servidor remoto

Alternativamente, la aplicación puede conectarse a un servidor **llama-server** que se ejecute en otro equipo de la red local. Para ello, se debe introducir la dirección IP y puerto del servidor (por ejemplo, **192.168.1.100:8089**) en la sección Servidor Remoto y pulsar **Conectar**.

Nota: El modo remoto es útil para equipos Android de gama baja: el modelo se ejecuta en un PC más potente y el dispositivo móvil actúa como interfaz.

5. Uso de la aplicación

5.1 Pantalla principal

La pantalla principal muestra el nombre de la aplicación, el estado del modelo y el acceso a las funciones principales:

- **Indicador de estado:** el badge verde «Modelo activo» confirma que el modelo está cargado. Si el modelo no se ha descargado aún, este indicador aparecerá en rojo y el mensaje «Modelo inactivo».
- **Nuevo Chat:** tarjeta principal para iniciar una nueva conversación.
- **Chats Recientes:** listado de conversaciones anteriores con su primera pregunta como título. Un contador indica el número total. Cada entrada tiene un botón (x) para eliminar la conversación individualmente.
- **Icono de ajustes** (esquina superior derecha): accede a la pantalla de configuración.




Figura 2. Pantalla principal de Teleco SLM.

5.2 Conversaciones

Al pulsar **Nuevo Chat** o seleccionar una conversación existente, se abre la pantalla de chat. El funcionamiento es similar a otras aplicaciones de mensajería:

- Escribir la pregunta en el campo de texto inferior y pulsar el botón de envío (flecha azul).
- La respuesta se genera de forma progresiva (token a token) en tiempo real.
- Los mensajes del usuario aparecen a la derecha (burbuja azul con icono de persona) y las respuestas del modelo a la izquierda (burbuja oscura con icono del modelo).
- Cada conversación se guarda automáticamente en la base de datos local (SQLite) y es accesible desde la sección Chats Recientes de la pantalla principal.

En la parte inferior de la pantalla de chat se muestra un aviso legal recordando que las respuestas pueden contener errores y no sustituyen la consulta de fuentes académicas oficiales.

5.3 Renderizado LaTeX

Teleco SLM soporta la renderización de expresiones matemáticas en formato LaTeX directamente dentro de las respuestas. El modelo ha sido entrenado para generar fórmulas usando delimitadores estándar: $\backslash(...\backslash)$ para expresiones en línea y $\backslash[...]$ para expresiones en bloque. Las fórmulas se renderizan automáticamente sin que el usuario tenga que realizar ninguna acción adicional.

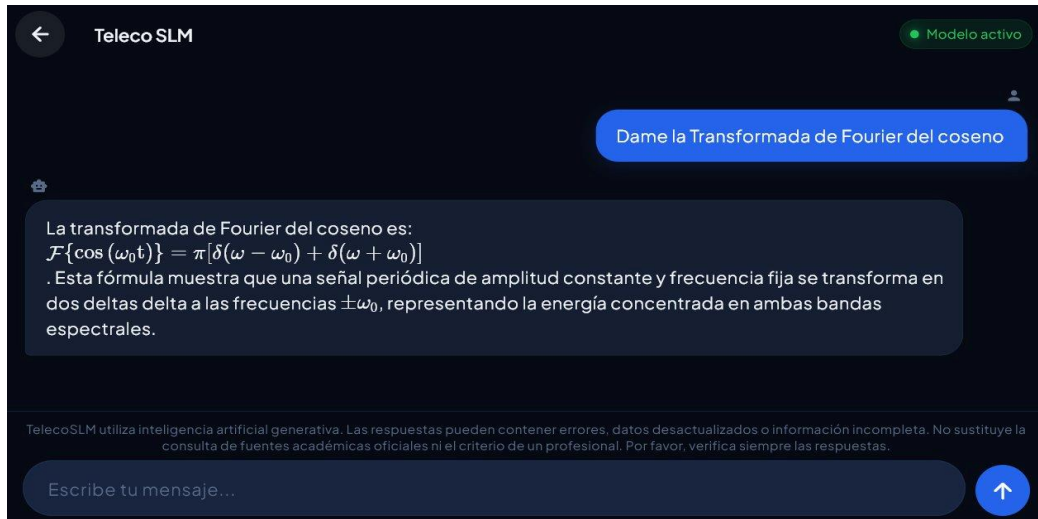


Figura 3. Pantalla de chat con respuesta generada incluyendo fórmula LaTeX.

6. Ajustes

La pantalla de Ajustes se organiza en las siguientes secciones:

Modelo Local

Muestra la información del modelo configurado (nombre, formato de cuantización, tamaño aproximado y modo de ejecución). Desde aquí se puede descargar el modelo desde HuggingFace o seleccionar un archivo GGUF almacenado localmente.

Servidor Remoto

Permite conectar la aplicación a una instancia de llama-server que se ejecute en la red local. Se introduce la dirección IP y puerto y se pulsa Conectar.

Rendimiento

Acceso al panel de Métricas de Inferencia, que se detalla en la sección 7.

Datos

El botón **Borrar todo el historial** elimina todas las conversaciones almacenadas en la base de datos local. Esta acción es irreversible.

Acerca de

Muestra la versión de la aplicación, una breve descripción y las tecnologías utilizadas: llama.cpp, SQLite y modo Offline.

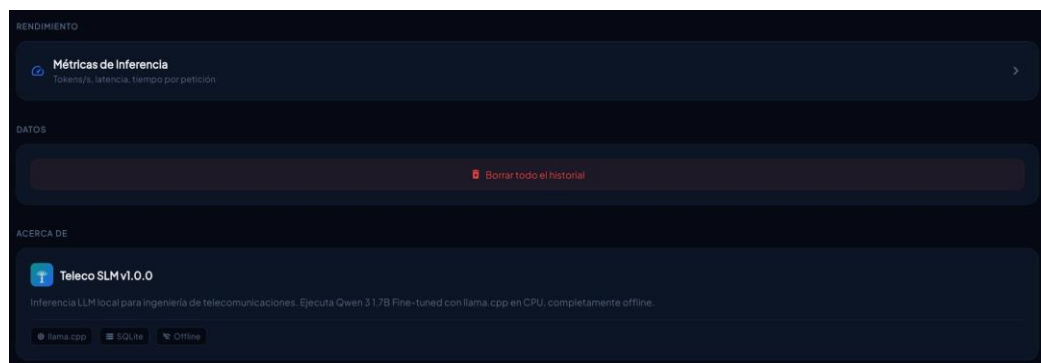


Figura 4. Ajustes — Rendimiento, Datos y Acerca de.

7. Métricas de inferencia

El panel de Métricas de Inferencia permite monitorizar el rendimiento del modelo en cada petición realizada. Se accede desde Ajustes > Rendimiento > Métricas de Inferencia.

Para cada consulta se registran las siguientes métricas:

Métrica	Descripción
Tokens generados	Número total de tokens producidos en la respuesta.
Tiempo al primer token	Latencia (en milisegundos) desde el envío de la petición hasta la generación del primer token.
Tiempo total	Duración total de la generación de la respuesta (en segundos).
Velocidad	Tasa de generación medida en tokens por segundo (tok/s).
Memoria (RSS)	Porcentaje de memoria RAM física utilizada por el proceso de inferencia.

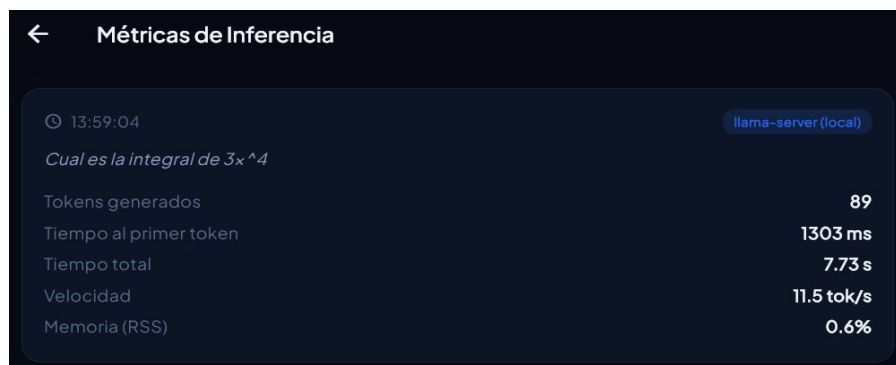


Figura 5. Panel de Métricas de Inferencia con datos de una consulta.

Cada entrada del historial de métricas incluye la hora de la petición, la fuente (llama-server local o remoto) y el texto de la consulta realizada. Esta información es útil para diagnosticar problemas de rendimiento o comparar la velocidad de inferencia en distintos dispositivos.

8. Gestión de datos

Toda la información generada por la aplicación se almacena exclusivamente en el dispositivo del usuario. Teleco SLM no envía datos a servidores externos en ningún momento. Los datos gestionados son:

- **Conversaciones:** almacenadas en una base de datos SQLite local. Cada conversación incluye los mensajes del usuario y las respuestas del modelo con marcas de tiempo.
- **Preferencias:** configuración de la aplicación (ruta del modelo, dirección del servidor remoto) almacenada mediante SharedPreferences.
- **Modelo:** el archivo GGUF del modelo se almacena en el directorio de la aplicación.

Eliminar conversaciones

Se pueden eliminar conversaciones individuales desde la pantalla principal pulsando el botón (×) junto a cada chat, o eliminar todo el historial desde Ajustes > Datos > Borrar todo el historial.

Advertencia: La eliminación del historial es irreversible. No es posible recuperar conversaciones borradas.

9. Solución de problemas

El indicador «Modelo activo» no aparece

El modelo no se ha descargado o la ruta del archivo es incorrecta. Acceder a Ajustes y verificar que la ruta del archivo GGUF es válida. Si es necesario, pulsar «Seleccionar archivo .gguf» para reconfigurar la ruta.

La descarga del modelo se interrumpe

Comprobar la conexión a internet y el espacio disponible en el dispositivo (~1,1 GB). Reiniciar la descarga desde Ajustes > Descargar modelo.

Las respuestas son muy lentas

La velocidad de inferencia depende del hardware del dispositivo. En dispositivos Android de gama baja, considerar utilizar el modo Servidor Remoto ejecutando llama-server en un PC con más recursos. Velocidades típicas: 8-15 tok/s en dispositivos móviles modernos, 15-30 tok/s en PCs de gama media.

La aplicación se cierra inesperadamente

Puede deberse a falta de memoria RAM. Cerrar otras aplicaciones en segundo plano y reiniciar Teleco SLM. El modelo requiere aproximadamente 1,5 GB de RAM libre.

Las fórmulas LaTeX no se renderizan correctamente

Verificar que la respuesta contiene los delimitadores correctos. En algunos casos, el modelo puede generar formato incorrecto. Reformular la pregunta solicitando explícitamente la fórmula.

No se puede conectar al servidor remoto

Verificar que ambos dispositivos están en la misma red local, que la dirección IP y puerto son correctos, y que llama-server está en ejecución en el equipo destino.

10. Información técnica

Componente	Detalle
Framework	Flutter (Android + Windows)
Motor de inferencia	llama.cpp (ARM64 NEON en Android, HTTP en Windows)
Modelo	Qwen 3 1.7B Fine-tuned (LoRA)
Formato del modelo	GGUF - Q4_K_M (~1,1 GB)
Contexto máximo	2.048 tokens
Base de datos	SQLite (almacenamiento local de conversaciones)
Configuración	SharedPreferences
Gestión de estado	Provider (Flutter)
Renderizado matemático	gpt_markdown (delimitadores LaTeX)
Filtrado thinking-mode	Máquina de estados con auto-retry /no_think
GPU (Android)	Deshabilitada (gpu_layers = 0, compatibilidad Adreno 612)
Versión	1.0.0

Teleco SLM v1.0.0 — Arturo Fierro Pardo
Universidad CEU San Pablo — Junio 2026